

Wymagania projektu zaliczeniowego

1. Organizacja projektu i zespołu

- Projekt realizowany w zespole
- Repozytorium kodu (np. GitHub/GitLab) z historią zmian
- Ustalone środowisko pracy:
 - Python

2. Wersja podstawowa modelu (baseline)

- Wybór problemu ML (klasyfikacja/regresja/analiza danych)
- Implementacja rozwiązania w **Jupyter Notebook**
- Notebook zawiera:
 - eksplorację danych (EDA)
 - preprocessing
 - trening modelu bazowego
 - ewaluację
- Notebook udostępniony online (np. GitHub, Kaggle, Colab)

3. Struktura projektu i pipeline

- Refaktoryzacja kodu:
 - podział na moduły Python (src/, data/, models/, notebooks/)
- Implementacja pipeline'u ML z użyciem:
 - **Kedro** (lub alternatyw)
- Pipeline obejmuje:
 - pobieranie danych
 - preprocessing
 - trening
 - ewaluację

4. Udoskonalanie modelu

- Implementacja systemu śledzenia eksperymentów:
 - np. MLflow / Weights & Biases
- Wykorzystanie AutoML:
 - np. Autogluon, TPOT, PyCaret
- Inżynieria cech:
 - selekcja cech
 - transformacje
- Strojenie hiperparametrów:
 - Grid Search / Random Search / Bayesian Optimization
- Porównanie kilku modeli

5. Pipeline produkcyjny

- Pipeline trenowania i inferencji wdrożony na wybranej infrastrukturze:
 - lokalnie / Docker / chmura (np. AWS, GCP, Azure)
- Udostępnienie modelu:
 - API (np. FastAPI / Flask)
- Monitoring:
 - logowanie predykcji
 - wykrywanie driftu danych
- Optymalizacja:
 - wybór architektury (np. batch vs real-time)
 - optymalizacja czasu i zasobów

6. MLOps / Repozytoria

Do wyboru jedna z dwóch ścieżek:

Opcja A – Repozytoria

- Wersjonowanie danych (np. DVC)
- Repozytorium cech (Feature Store, np. Feast)

- Repozytorium modeli (np. MLflow Model Registry)

Opcja B – Automatyzacja MLOps

- CI (Continuous Integration):
 - testy, linting (np. GitHub Actions)
- CD (Continuous Deployment):
 - automatyczne wdrożenia
- Continuous Training:
 - automatyczne ponowne trenowanie modelu

7. Dokumentacja

- Kompleksowa dokumentacja projektu:
 - opis problemu
 - opis danych
 - architektura systemu
 - sposób uruchomienia
- Wizualizacja architektury:
 - diagram (np. draw.io)
- README w repozytorium

8. Podsumowanie i prezentacja

- Prezentacja końcowa (10–15 min):
 - problem i rozwiązanie
 - pipeline ML
 - wyniki
 - wdrożenie
- Demo działania projektu (np. API lub notebook)